第一讲：关系型数据库管理系统绪论

知春路遇上八里桥

<2024-05-06 Mon>

1. 数据库简介
2. 关系型数据库
3. SQL - 结构化查询语言

1

数据库简介

RDMS 是什么

1. RDMS（Relational Database Management System）是关系数据库管理系统
   - MySQL（开源），海豚具有很高的智商
   - Postgresql（开源），大象有着惊人的记忆力
   - Oracle（老牌商业化产品，闭源）
   - ...
2. RDMS 广泛运用于互联网等行业基础组件，它包含以下基本功能：
   - 管理用户的数据集
   - 是世界上最常用的软件

课程目标

1. 本课程是介绍 RDMS 的设计和实现，不是介绍如何使用 RDMS
   - 数据库的概念、设计和实现
   - 以 MySQL 源代码实现为例进行讲解
2. 适合以下人群
   - 有一定业务系统开发经验，每天 CURD 吐了的同学
   - 对关系型数据库内核设计感兴趣的同学
   - 在技术面试中经常被问到 MySQL 相关问题，想要深入了解源码的同学
   - 经常被问为什么 xxx 实现不了，希望从数据库底层原理怼回去的同学
3. 本课程需要掌握以下基础技能
   - 对 SQL 语言有基础了解
   - C/C++ 的编程经验
   - 大学课程中选修过《数据库概念》类似的课程

课程计划

1. 授课时间 <2024-05-06 Mon> 至 <2024-09-01 Sun>
   - 先暂定四个月
2. 课程准备时间 <2024-03-26 Tue>
   - 以最新的 MySQL 8.0.x => 即 8.0.37 源码作为依据进行分析
3. 涉及到以下相关话题：
   - 服务端 (mysql-server)
     1. 启动流程
     2. C/S 通信模型
     3. 解析器 Parser vs 优化器 Optimizer
     4. 底层存储：表空间和内存模型
   - 存储引擎 (InnoDB)
     1. MVCC 和事务
     2. 内存管理、磁盘管理
     3. 并发和锁
   - MySQL 周边
     1. binlog, gdb, mtr 等

2

关系型数据库

关系型数据库起源

1970 年，IBM 研究员 E.F.Codd 博士在刊物 Communication of the ACM 上发表了一篇名为 “A Relational Modelof Data for Large Shared Data Banks” 的论文，提出了关系模型的概念，奠定了关系模型的理论基础。

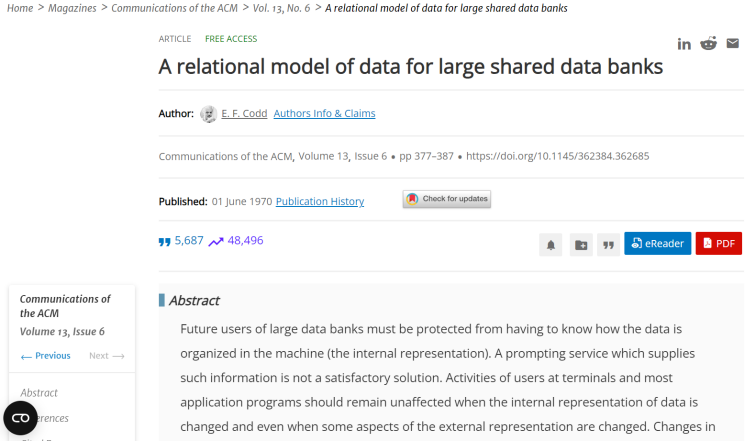

数据库中的表

关系数据库一般处理的是二维表，例如：

- **员工表** employees(emp_no, birth_date, first_name, ···)

emp_no	birth_date	first_name	last_name	gender	hire_date
10001	1953-09-02	Georgi	Facello	M	1986-06-26
10002	1964-06-02	Bezalel	Simmel	F	1985-11-21
10003	1959-12-03	Parto	Bamford	M	1986-08-28

- **部门表** departments(dept_no, dept_name)

dept_no	dept_name
d009	Customer Service
d005	Development
d002	Finance

数据库存储形态

1. 表有多种存储，早期直接使用裸文件存储：
   - CSV/TXT（纯文本文件）
   - Excel 表格（二进制格式）
   - 由数据库软件统一管理
2. 在数据库系统中表可以通过 SQL 语言查询出来，查询返回是结构集

```
mysql> select * from employees limit 3;
+--------+------------+------------+-----------+--------+------------+
| emp_no | birth_date | first_name | last_name | gender | hire_date  |
+--------+------------+------------+-----------+--------+------------+
|  10001 | 1953-09-02 | Georgi     | Facello   | M      | 1986-06-26 |
|  10002 | 1964-06-02 | Bezalel    | Simmel    | F      | 1985-11-21 |
|  10003 | 1959-12-03 | Parto      | Bamford   | M      | 1986-08-28 |
+--------+------------+------------+-----------+--------+------------+
3 rows in set (0.00 sec)
```

读取文件中的数据

- 早期数据存储使用文本文件或格式化文件
- 直接通过代码操作数据的读取/更新/删除
- 下面是使用 Python 读取 csv 的例子

```python
import csv

# 打开文件
with open('data.csv', 'r') as f:
    # 创建一个 csv.reader 对象
    reader = csv.reader(f)

    # 遍历每一行
    for row in reader:
        # 读取每一行数据
        print(row)
```

模型 vs 模式

1. 模型（model），也称数据模型（data model），是现实世界特征的模拟和抽象
   - 数据结构：常见结构有层次结构、网状结构、关系结构
   - 数据操作：数据操作是对系统动态特性的描述
     1. 指对数据库中各种对象的实例运行执行的操作的集合
     2. 数据库主要有检索和更新两大类操作
     3. 数据模型必须定义这些操作的确切含义、操作符号、操作规则
   - 完整性约束：数据的约束条件是一组完整性规则的集合
2. 模式（schema），也称逻辑模式（physical schema），是模型对于的数据结构
   - 是数据库中全体数据的逻辑结构和特征的描述，
   - 是所有用户的公共数据视图

更多模型例子

- Relational (**本课程关注重点**)
- Key/Value
- Graph
- Document / Object
- Wide-Column / Column-family
- Array / Matrix / Vectors
- Hierarchical
- Network
- Multi-Value

关系模型

1. 关系模型（Relational Model）包含三要素，参考之前模型的说明
   - 数据结构（Structure），数据操作（Manipulation），完整性（Integrity）
2. 关系是一个无序的集合
   - n 元关系包含 n 个属性
   - 例如：departments(dept_no, dept_name) 是 2 元关系
3. 元组（tuple）是一系列属性值，例如：dept_no, dept_name
   - 属性值是原子的
   - NULL 表示空值，每个属性都应包含空值
4. 主键（Primary Key）标记每个元组：
   - 通过 `SEQUENCE`（PG/ORACLE）或 `AUTO_INCREMENT`（MySQL）实现
5. 外键（Foreign Key）通过一个属性印射到其他关系的元组
6. DML（数据操作语言）表示对关系数据的存取
   - 可以使用关系代数来描述，稍后介绍

关系代数

1. 关系代数是一种 过程化 查询语言
   - 它包含运算的集合，运算以一个或两个关系为输入，产生新的关系作为结果
   - n 元关系的代数表示为：$R(a_1, a_2, \cdots, a_n)$
2. 关系代数基本运算[1]包括，通过链式调用可以完成对数据的操作

运算符	语法	英文名	中文名
σ	$\sigma_{\text{predicate}}(R)$	Selection	选择
$\prod$	$\prod_{a_1,a_2,\cdots,a_n}(R)$	Projection	投影
$\cup$	$R_1 \cup R_2$	Union	并
$\cap$	$R_1 \cap R_2$	Intersection	交
$-$	$R_1 - R_2$	Difference	集合差
$\times$	$R_1 \times R_2$	Cartesian Product	笛卡尔积
$\bowtie$	$R_1 \bowtie R_2$	Natural Join	自然链接

[1]关系代数的表示法的含义后面通过 SQL 来说明

关系代数 vs SQL [2]

假设存在关系：$R(a,b,c)$ ，$S(a,b,x,y)$ 和 $T(a,b,c)$ ，则：

1. 选择运算：$\sigma_{a>3}(R)$

```
select * from R where a > 3;
```

2. 投影运算：$\prod_{a,b}(R)$

```
select a, b from R;
```

3. 笛卡尔积（R 和 S 所有可能的有序对）：$R \times S$ ，结果包含属性 a,b,c,a',b',x,y

```
select * from R, S;
select * from R cross join S;
```

4. 自然连接（相同属性相等后连接）：$R \bowtie S$ ，结果包含属性 a,b,c,x,y

```
select * from R natural join S;
select * from R join S using (a, b);
```

[2]注意 SQL 关键字不区分大小写

关系代数 vs SQL （续）

假设存在关系：$R(a,b,c)$ ， $S(a,b,x,y)$ 和 $T(a,b,c)$ ， 则：

1. 选择后投影：$\prod_{a,b}\left(\sigma_{c=1}(R)\right)$

```
select a, b from (select * from R where c = 1);
-- 简化版
select a, b from R where c = 1;
```

2. 交集和投影：$\prod_{a}(R \cap T)$

```
select a from
  (select * from R intersect select * from T);
```

3. 选择和并集：$\left(\prod_{a,b}(\sigma_{c=1}(R))\right) \bigcup \left(\prod_{a,b}(\sigma_{x>2}(S))\right)$

```
select a, b from R where c = 1
  union all
select a, b from S where x > 2;
```

计算次序

假设存在关系：$R(a,b,c)$ 和 $S(a,b,x,y)$ ，则：

1. 情形一：$\sigma_{a=3}(R \bowtie S)$

```
select * from
  (select * from R natural join S) t
    where t.a = 3;
```

2. 情形二：$R \bowtie \sigma_{a=3}(S)$

```
select * from
  R natural join (select * from S where a = 3);
```

3. 上述两种情形结果相同，但是执行效率存在差异

3

SQL - 结构化查询语言

SQL 基础

1. SQL 全称 Structured Query Language，有时也称为 Query
2. Data Manipulation Language (DML)
   - `insert/select/delete/update`
3. Data Definition Language (DDL)
   - `create table/drop table`
4. Data Control Language (DCL)
   - `create user ... identified by ...`
   - `grant`
5. 其他功能：
   - 查看定义（Definition）
   - 数据完整性操作（Integrity）
   - 事务（Transactions）

DDL

1. **建表语句：设置表中列名，类型等**

```sql
create table `employees` (
  -- 定义字段
  `emp_no` int not null,                    -- 整数类型
  `birth_date` date not null,               -- 日期类型
  `first_name` varchar(14) not null,        -- Varchar 类型
  `last_name` varchar(16) not null,         --
  `gender` enum('M','F') not null,          -- 枚举类型
  `hire_date` date not null,                --
  primary key (`emp_no`)                    -- 设置主键
);
```

2. **删表语句：直接删除表中的所有数据**

```sql
drop table employees;                       -- 删除表
```

DML - 查询

1. 查询语句，包含过滤、分组功能

```
select vend_id, count(*) as num_prod                -- 查询字段
  from products                                     -- 指定数据表
 where prod_price >= 10                             -- 过滤条件
 group by vend_id                                   -- 分组字段
having count(*) >= 2;                               -- 分组条件
```

2. 子查询，设置别名

```
select cust_name, cust_state,                       -- 查询字段
       (select count(*)                             -- 子查询
          from orders                               --
         where orders.cust_id = customers.cust_id)  --
       as num_orders                                -- 设置别名
  from customers                                    --
 order by cust_name;                                --
```

DML - 更新

1. **插入数据**

```
insert into
  employees(emp_no, first_name, gender, hire_date) -- 插入的列
  value ('12345', 'Jack', 'M','1999-01-23');       -- 插入的值
```

2. **更新数据**

```
update employees                                   -- 需要更新的表
   set hire_date = '2003-10-10'                    -- 需要更新的字段
 where emp_no = '12345';                           -- 更新的过滤条件
```

3. **删除数据**

```
delete from employees where emp_no = '12345';
```

Join

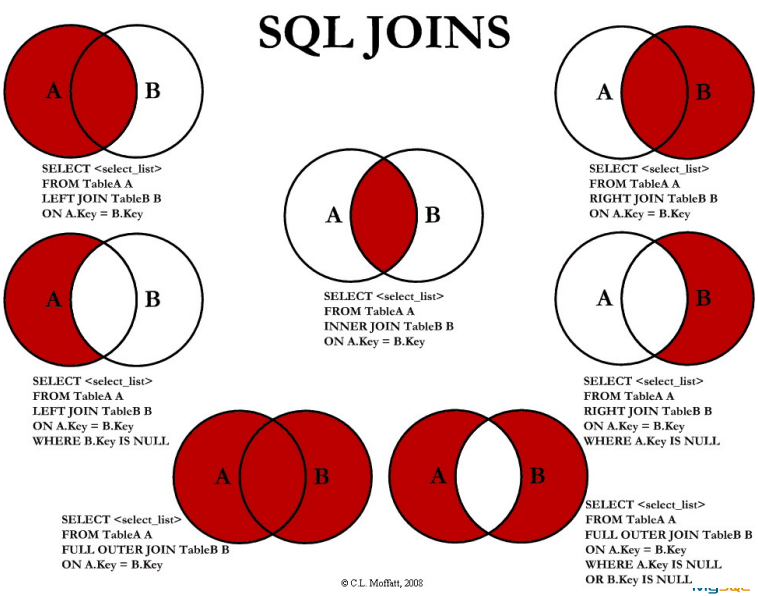
SQL JOINS
A
B
SELECT <select_list>
FROM TableA A
LEFT JOIN TableB B
ON A.Key = B.Key
SELECT <select_list>
FROM TableA A
INNER JOIN TableB B
ON A.Key = B.Key
SELECT <select_list>
FROM TableA A
RIGHT JOIN TableB B
ON A.Key = B.Key
SELECT <select_list>
FROM TableA A
LEFT JOIN TableB B
ON A.Key = B.Key
WHERE B.Key IS NULL
SELECT <select_list>
FROM TableA A
RIGHT JOIN TableB B
ON A.Key = B.Key
WHERE A.Key IS NULL
SELECT <select_list>
FROM TableA A
FULL OUTER JOIN TableB B
ON A.Key = B.Key
SELECT <select_list>
FROM TableA A
FULL OUTER JOIN TableB B
ON A.Key = B.Key
WHERE A.Key IS NULL
OR B.Key IS NULL
© C.L. Moffatt, 2008

更多特性

1. 聚合函数：`avg()/min()/max()/sum()/count()`
2. 数据去重：`select count(distinct first_name) ...`
3. 字符串操作符：`where first_name like 'A%'`
4. 嵌套查询：`select ... where sid in (select id from student)`
5. 窗口函数：`select *, row_number() over (order by cid) from enrolled ...`
6. 公共表达式（CTE）：`with t1 as (select ...) select * form t1`
7. CTE 实现递归：打印 1 到 10 的序列

```
1 with recursive t (counter) as (                    -- 定义 CTE 及字段别名
2   (select 1)                                       -- 递归初始条件
3     union all
4   (select counter + 1 from t where counter < 10)   -- 递归逻辑
5 ) select * from t;
```

结束