第十讲：MySQL 语法分析器的设计与实现

知春路遇上八里桥

<2024-06-06 Thu>

1

前情提要

执行流程

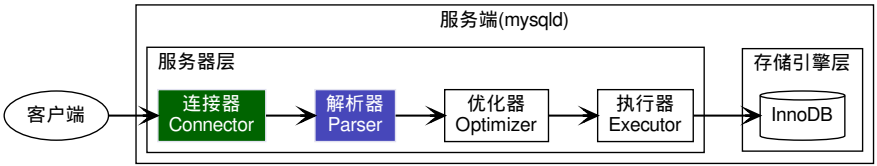
服务端(mysqld)
服务器层
存储引擎层
客户端
连接器
Connector
解析器
Parser
优化器
Optimizer
执行器
Executor
InnoDB

本节内容

- 连接器
  - ☑ 连接管理器 Connection Manager
  - ☑ 线程管理器 Thread Manager
  - ☑ 用户模块 User Module
- 解析器
  - ☑ 网络模块 Net Module
  - ☑ 派发模块 Commander Dispatcher
  - ☑ 词法分析 Lexical Analysis
  - ☐ 语法分析 Syntax Analysis

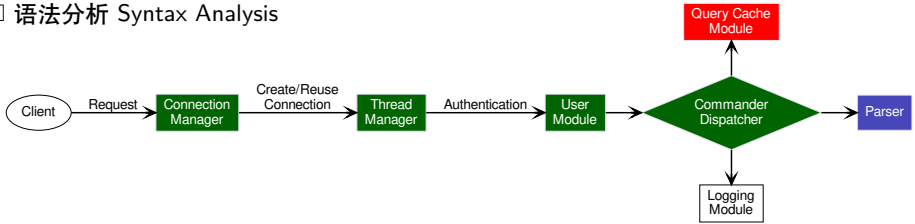

2

语法分析

语法树构建流程

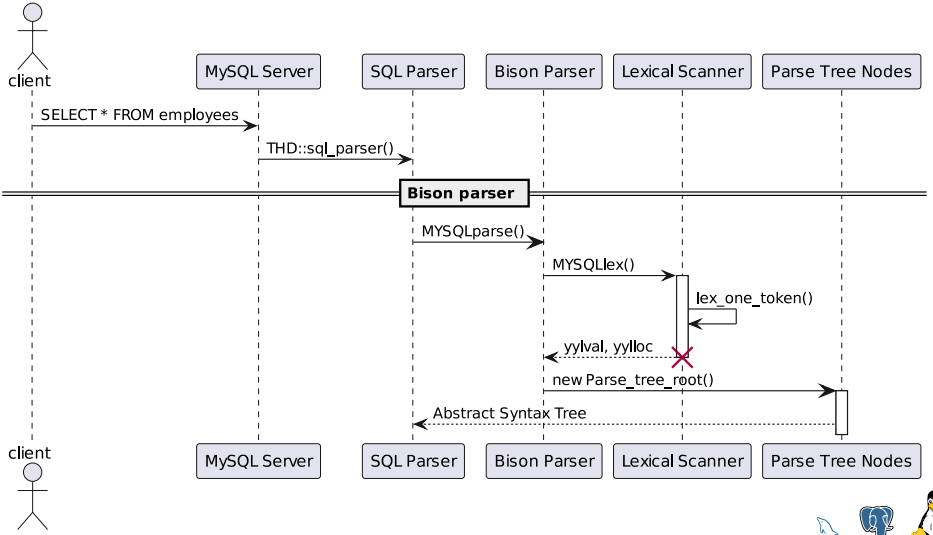
client
MySQL Server
SQL Parser
Bison Parser
Lexical Scanner
Parse Tree Nodes
SELECT * FROM employees
THD::sql_parser()
Bison parser
MYSQLparse()
MYSQLlex()
lex_one_token()
yylval, yylloc
new Parse_tree_root()
Abstract Syntax Tree
client
MySQL Server
SQL Parser
Bison Parser
Lexical Scanner
Parse Tree Nodes

语法分析要点

1. bison 语法分析器使用 LALR 算法 [1]，该算法能够自动处理左递归
2. `dispatch_sql_command()` 开始进入语法解析
3. `parse_sql()` 入口函数
4. `THD::sql_parser()`
5. `MYSQLparse()`
   - 进入编译中间文件 ⋆ build/sql/sql_yacc.cc
   - 调用 `yyparse()` 函数，该函数是 bison 生成的
   - 生成解析树 Parse Tree
6. `LEX::make_sql_cmd()`
   - 生成抽象语法树 AST (Abstract Syntax Tree)

[1] https://ustc-compiler-principles.github.io/2023/lab1/Bison/

3

解析树数据结构

解析树根节点 Parse_tree_root

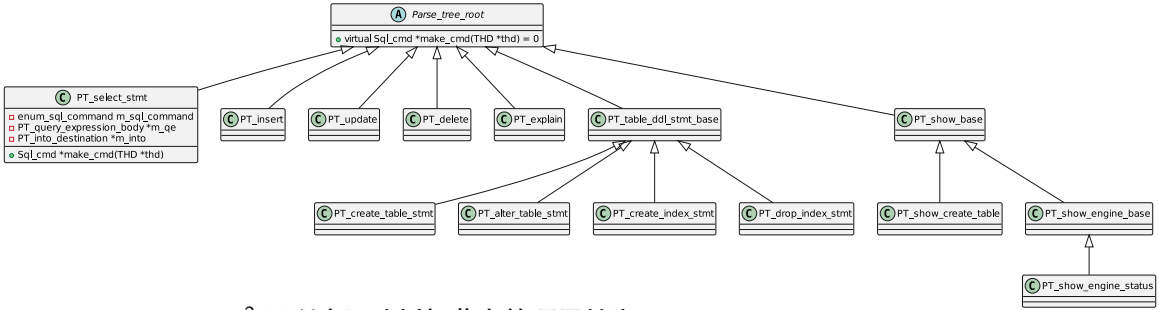

- Parse_tree_root [2] 是所有语法树根节点的顶层基类
- 每种类型的 Query 对应的 root 类不同
  - `SELECT` 语句 ⇒ `PT_select_stmt` 类
  - `UPDATE` 语句 ⇒ `PT_update` 类
  - `DELETE` 语句 ⇒ `PT_delete` 类
- 相关类实现见 ⋆ sql/parse_tree_*

[2] https://dev.mysql.com/doc/dev/mysql-server/8.0.37/classParse__tree__root.html

SELECT 语句的根节点 PT_select_stmt

1. SELECT 语句根节点实现类
   - ⋆ sql/parse_tree_nodes.h

```
1689  class PT_select_stmt : public Parse_tree_root {
1690    typedef Parse_tree_root super;
1691
1692   public:
1693    /**
1694      @param qe The query expression.
1695      @param sql_command The type of SQL command.
1696    */
1697    PT_select_stmt(enum_sql_command sql_command, PT_query_expression_body *qe)
1698        : m_sql_command(sql_command),
1699          m_qe(qe),
1700          m_into(nullptr),
1701          m_has_trailing_locking_clauses{false} {}
```

2. SELECT 语句的规范见官网 [3]

[3] https://dev.mysql.com/doc/refman/8.0/en/select.html

解析树节点 Parse_tree_node

- Parse_tree_node [4] 是语法树节点的基类
- 最重要的是 `Item` 类，相关类实现见 ⋆ sql/item_*

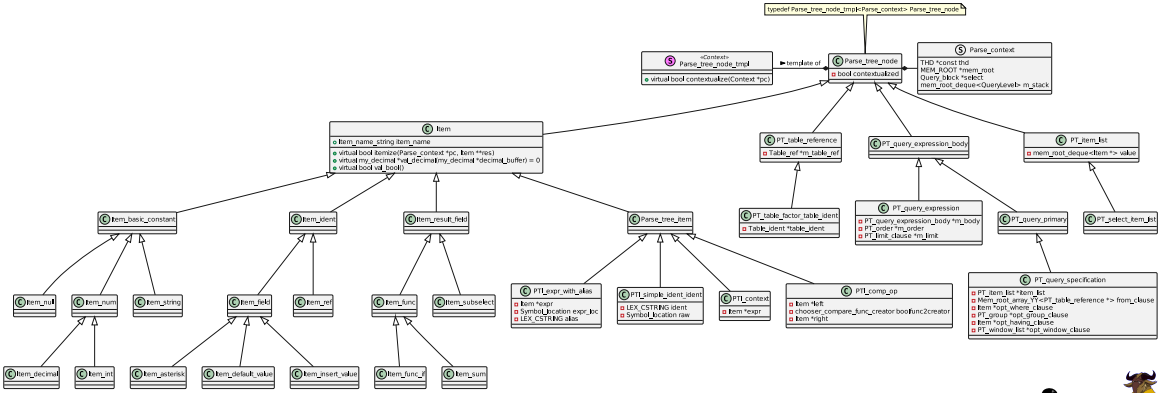

[4] https://dev.mysql.com/doc/dev/mysql-server/8.0.37/classParse___tree___node___tmpl.html

Item 类实现

- bison 解析后会生成包含 Item 节点的树，这里成为解析树
  - Item 有形如 `val_xxx()` 方法，`val_int()` / `val_str()` 是内置的求值函数
  - 解析树里会有一部分是 `PTI_` 开头的 Item，它们都是继承自 `Parse_tree_item`
    1. 在 contextualize 阶段时，会对这些 `PTI_item` 进行 `itemize()`
    2. 将它们从解析树节点转化成真正意义的表达式树节点
- Item 是语法树中的基础对象，表示 Query 中的一个具体的项目
  - 类定义具体见文件 ⋆ sql/item.h 的定义如下

```
851  class Item : public Parse_tree_node {
852    typedef Parse_tree_node super;
 ⋮
3559   virtual void allow_array_cast() {}
3560 };
```

- `itemize()` 是调用 `contextualize()` 是构造最终的 Item 对象

```
virtual bool itemize(Parse_context *pc, Item **res)
```

典型的 Item 举例

- 常量节点/值节点 `Item_base_constant`
  - 存储常量值
- 字段节点/列节点 `Item_field`
  - 存储列字段的相关元信息
- 函数计算节点 `Item_func`
  - 系统函数，例如 +, -, *, /, >=, <> 等系统提供的基本函数型操作
  - 常用函数，例如数学函数、加密函数等
- 逻辑计算节点 `Item_cond`
  - 主要是 `and` , `or`, `not` 等条件操作
  - 这类函数可以看作是输入值为 1 个或 2 个布尔参数，返回值为布尔的特殊函数
- 聚合函数计算 `Item_sum`
  - 分为系统聚合函数和 UDF。系统聚合函数包括 sum、count、avg、max、min 等

4

解析流程

BISON 中的 query_expression 规则

- Query 表达式的求值规则

```
9914  query_expression:
9915            query_expression_body
9916            opt_order_clause
9917            opt_limit_clause
9918            {
9919              $$ = NEW_PTN PT_query_expression($1.body, $2, $3);
9920            }
9921          | with_clause
9922            query_expression_body
9923            opt_order_clause
9924            opt_limit_clause
9925            {
9926              $$= NEW_PTN PT_query_expression($1, $2.body, $3, $4);
9927            }
9928          ;
```

创建语法树节点

- bison 规则的原始代码

```
{
  $$= NEW_PTN PT_query_expression($1, $2.body, $3, $4);
}
```

- 自动生成的 sql_yacc.cc 代码，【添加一些换行符】

```
#line 9918 "/opt/src/mysql-server/sql/sql_yacc.yy"
          {
            (yyval.query_expression) = NEW_PTN PT_query_expression(
              (yyvsp[-2].query_expression_body_opt_parens).body,
              (yyvsp[-1].order),
              (yyvsp[0].limit_clause));
          }
```

- 代码中用到的宏定义

```
#define NEW_PTN new(YYMEM_ROOT)
#define YYMEM_ROOT (YYTHD->mem_root)
```

BISON 语法分析流程

- bison 解析的 LALR 算法可以通过日志简单分析流程，通过 debug=d,parser_debug 选项开启

```
Starting parse                                  <= 开始解析
Entering state 0                                <= 进入解析，初始化解析
Stack now 0
Reading a token                                 <= 读取一个 token
Next token is token SELECT_SYM (: )             <= 解析到 select
Shifting token SELECT_SYM (: )                  <= 移进 select 符号
Entering state 42                               <= 进入下一个状态
...
Reducing stack by rule 1342 (line 9819):        <= 对表达式进行规约
   $1 = nterm query_expression (: )
-> $$ = nterm select_stmt (: )
...                                             <= 此处省略一堆操作
Cleanup: popping token "end of file" (: )       <= 读取到文件结束符
Cleanup: popping nterm start_entry (: )         <= 解析结束后清理工作
```

- 解析算法参考 bison 文档说明 [5]

[5] https://www.gnu.org/software/bison/manual/html_node/Algorithm.html

查看 BISON 解析后的语法树

- THD::sql_parser() 代码，具体见 ⋆ sql/sql_class.cc

```
3058  Parse_tree_root *root = nullptr;
3059  if (MYSQLparse(this, &root) || is_error()) {
```

- bison 解析过程在 THD::sql_parser() 中发生，解析完成生成 root 变量

```
(gdb) b THD::sql_parser()
(gdb) p *root
$4 = {_vptr.Parse_tree_root = 0x55555e1fca50 <vtable for PT_delete+16>}
(gdb) i vtbl root
vtable for 'Parse_tree_root' @ 0x55555e1fca50 (subobject @ 0x7fff30110600):
[0]: 0x5555594ac070 <PT_delete::~PT_delete()>
[1]: 0x5555594ac0a2 <PT_delete::~PT_delete()>
[2]: 0x55555948e196 <PT_delete::make_cmd(THD*)>
(gdb)
```

通过 Query 构建的解析树

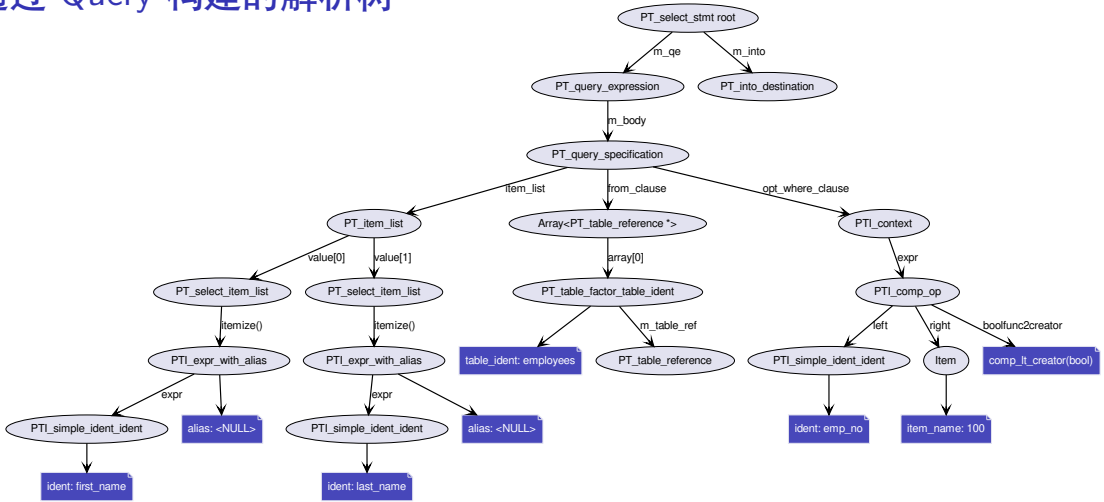


```
select first_name, last_name from employees where emp_no < 100;
```

5

代码分析

LEX 数据结构

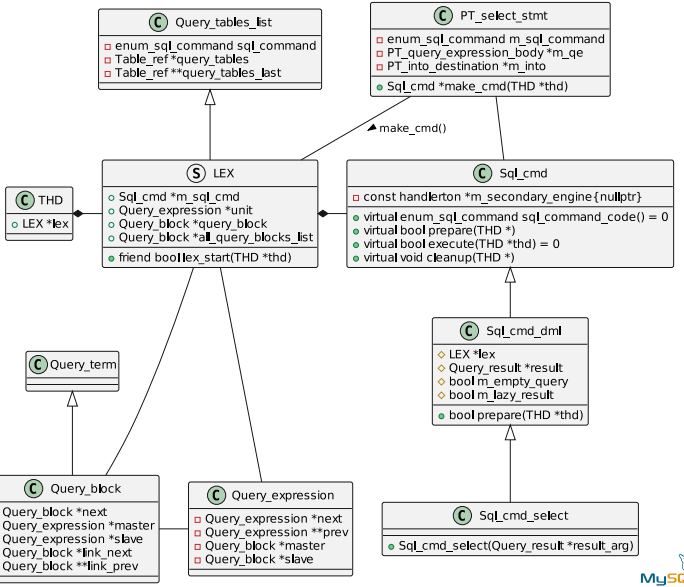
Query_tables_list
enum_sql_command sql_command
Table_ref *query_tables
Table_ref **query_tables_last
PT_select_stmt
enum_sql_command m_sql_command
PT_query_expression_body *m_qe
PT_into_destination *m_into
Sql_cmd *make_cmd(THD *thd)
make_cmd()
LEX
Sql_cmd *m_sql_cmd
Query_expression *unit
Query_block *query_block
Query_block *all_query_blocks_list
friend bool lex_start(THD *thd)
THD
LEX *lex
Sql_cmd
const handlerton *m_secondary_engine{nullptr}
virtual enum_sql_command sql_command_code() = 0
virtual bool prepare(THD *)
virtual bool execute(THD *thd) = 0
virtual void cleanup(THD *)
Sql_cmd_dml
LEX *lex
Query_result *result
bool m_empty_query
bool m_lazy_result
bool prepare(THD *thd)
Query_term
Query_block
Query_block *next
Query_expression *master
Query_expression *slave
Query_block *link_next
Query_block **link_prev
Query_expression
Query_expression *next
Query_expression **prev
Query_block *master
Query_block *slave
Sql_cmd_select
Sql_cmd_select(Query_result *result_arg)

THD::sql_parser()

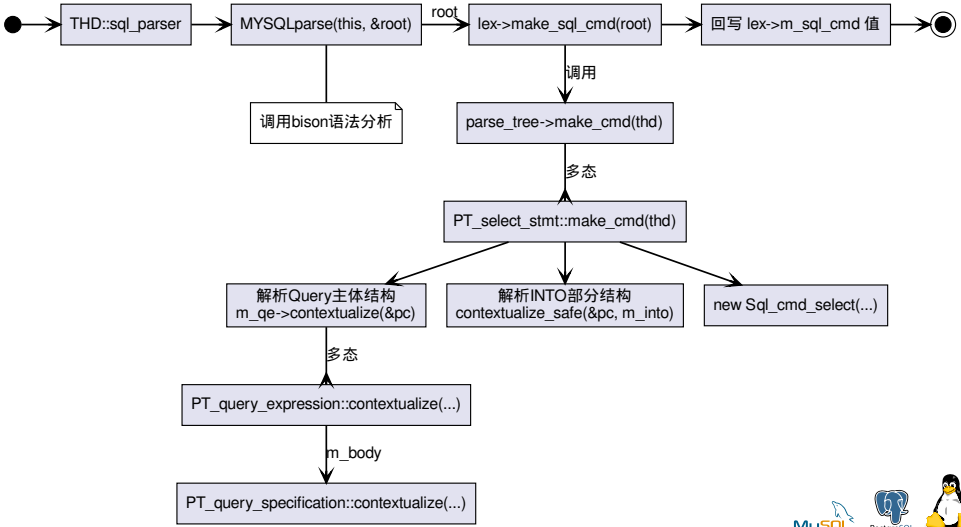

make_cmd

- SELECT 语句根节点创建 AST
  - 代码节选自 ⋆ sql/parse_tree_nodes.cc 的 1689 行

```
Sql_cmd *PT_select_stmt::make_cmd(THD *thd) {
  if (m_qe->contextualize(&pc)) {  // 处理 query_expression
    return nullptr;
  }
  if (contextualize_safe(&pc, m_into)) {  // 处理 INTO 子句
    return nullptr;
  }
  // 调用 placement new 构造对象
  if (thd->lex->sql_command == SQLCOM_SELECT)
    return new (thd->mem_root) Sql_cmd_select(thd->lex->result);
  else  // (thd->lex->sql_command == SQLCOM_DO)
    return new (thd->mem_root) Sql_cmd_do(nullptr);
}
```

- make_cmd() 函数可以将代码上下文化，placement new [6] 出 Sql_cmd 对象 [7]

[6] 在已经被分配但尚未处理的 (raw) 内存中构造对象

[7] https://dev.mysql.com/doc/dev/mysql-server/8.0.37/classSql___cmd.html

Query_expression 和 Query_block

- Query_expression 表示查询表达式
- Query_block 表示查询块
- 查询表达式包含一个或多个查询块
  - 多个表示我们有 UNION 查询
- 这两个类都有 master、slave、next 和 prev 四个字段。
  - 对于 Query_block 类
    1. master 和 slave 指向 Query_expression 类型的对象
  - 对于 Query_express 类:
    1. 它们指向 Query_block
    2. master 是指向外部节点的指针
    3. slave 是指向第一个内部节点的指针
    4. neighbors 是同一级别上的两个 Query_block 或 Query_expression 对象
- 参考 ⋆ sql/sql_lex.h 中 Query_expression 定义前的注释

```
623  class Query_expression {
```

Query_expression 和 Query_block 关系举例

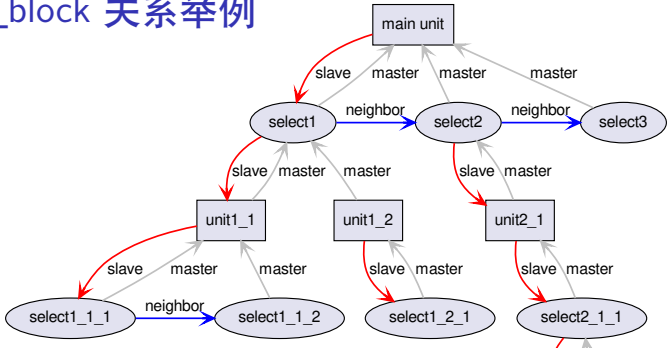


```
select *
  from table1
  where table1.field IN (select * from table1_1_1 union
                         select * from table1_1_2)
  union
select *
  from table2
  where table2.field=(select (select f1 from table2_1_1_1_1
                              where table2_1_1_1_1.f2=table2_1_1.f3)
                      from table2_1_1
                      where table2_1_1.f1=table2.f2)
  union
select * from table3;
```

结束