第三十讲：InnoDB Buffer Pool 的设计与实现

知春路遇上八里桥

<2025-02-16 Sun>

1

BufferPool 引入

InnoDB 架构

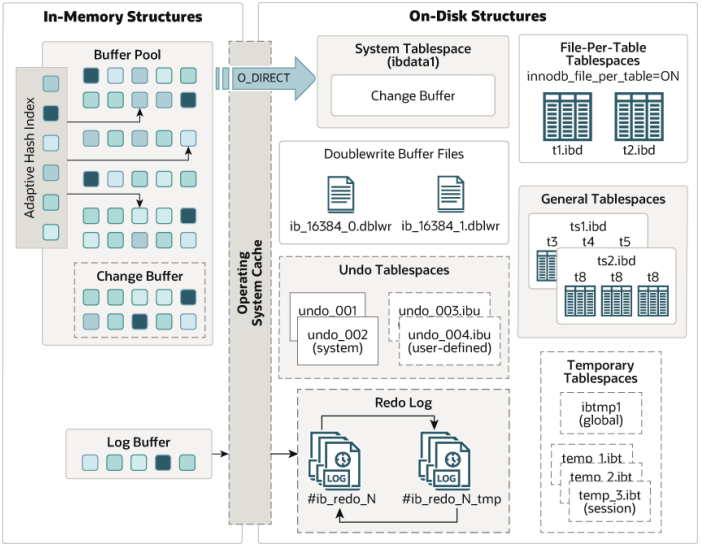
In-Memory Structures
On-Disk Structures
Buffer Pool
Adaptive Hash Index
Change Buffer
Log Buffer
O_DIRECT
Operating System Cache
System Tablespace (ibdata1)
Change Buffer
File-Per-Table Tablespaces
innodb_file_per_table=ON
t1.ibd
t2.ibd
Doublewrite Buffer Files
ib_16384_0.dblwr
ib_16384_1.dblwr
General Tablespaces
ts1.ibd
t3
t4
t5
ts2.ibd
t8
t8
t8
Undo Tablespaces
undo_001
undo_002 (system)
undo_003.ibu
undo_004.ibu (user-defined)
Temporary Tablespaces
ibtmp1 (global)
temp_1.ibt
temp_2.ibt
temp_3.ibt (session)
Redo Log
LOG
LOG
#ib_redo_N
#ib_redo_N_tmp

BufferPool 设计

- BufferPool [1] 是缓存 InnoDB 表和索引数据的内存结构
  - InnoDB 没有使用操作系统的缓存，自己实现了一套 BufferPool
  - 缓存数据到内存中可以提高数据库的性能
  - BufferPool 是 MySQL 中最占用内存的内存模块
  - 在专用数据库服务器中，80% 的内存都被 BufferPool 使用
- BufferPool 相关的核心概念
  - Buffer Pool Instance，Buffer Pool 实例
  - Buffer Chunks，包括两部分：
    1. 数据页和数据页对应的控制体，控制体中有指针指向数据页
    2. Buffer Chunks 是操作系统最低层的物理块
    3. 在启动阶段从操作系统申请，直到数据库关闭才释放
  - Page 数据页，与磁盘结构中的 Page 一致
  - 常见链表：free list / LRU list / flush list 等

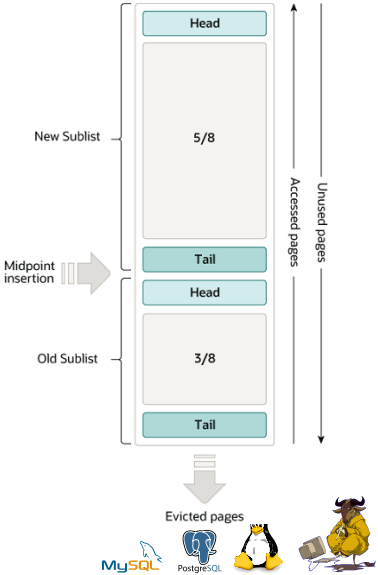

[1] https://dev.mysql.com/doc/refman/8.0/en/innodb-buffer-pool.html

查看 BufferPool 状态

```
mysql> show engine innodb status\G
此处省略一些其他输出
----------------------
BUFFER POOL AND MEMORY
----------------------
Total large memory allocated 0
Dictionary memory allocated 639306
Buffer pool size   8192
Free buffers       5687
Database pages     2496
Old database pages 941
Modified db pages  0
Pending reads      0
Pending writes: LRU 0, flush list 0, single page 0
Pages made young 0, not young 0
0.00 youngs/s, 0.00 non-youngs/s
Pages read 2354, created 142, written 201
38.27 reads/s, 0.00 creates/s, 0.03 writes/s
Buffer pool hit rate 570 / 1000, young-making rate 0 / 1000 not 0 / 1000
Pages read ahead 31.96/s, evicted without access 0.00/s, Random read ahead 0.00/s
LRU len: 2496, unzip_LRU len: 0
I/O sum[0]:cur[0], unzip sum[0]:cur[0]
----------------------
```

BufferPool 中的逻辑结构

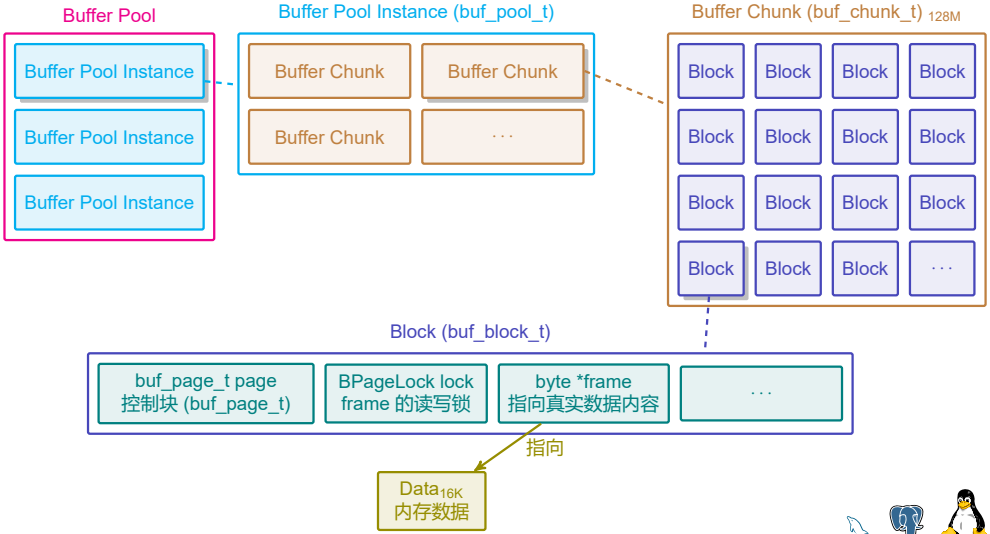

重要数据结构说明

1. buf_pool_t
   - 存储 BufferPool 实例级别的控制信息，例如 mutex，instance_no 等
   - 还存储了各种逻辑链表的链表根节点，例如：Zip Free 这个二维数组也在其中
2. buf_chunk_t
   - 是一块连续分配的内存
   - 由若干 block 组成，多个 chunk 构成了 buf_pool_t 实例
3. buf_block_t
   - 这个就是数据页的控制体，用来描述数据页部分的信息 (大部分信息在 buf_page_t 中)
   - buf_block_t 中首个字段就是 buf_page_t，放在首位为了 buf_block_t 和 buf_page_t 相互转换
   - buf_block_t 中另一个重要字段是 frame，指向真正存数据的数据页
   - buf_block_t 还存储了 Unzip LRU List 链表的根节点
   - 另外一个比较重要的字段就是 block 级别的 mutex
4. buf_page_t
   - 这个可以理解为另外一个数据页的控制体，大部分的数据页信息存在其中
   - 压缩页的信息包括压缩页的大小，压缩页的数据指针
   - 如果某个压缩页被解压了，解压页的数据指针是存储在 buf_block_t 的 frame 字段里

BufferPool 核心的数据结构

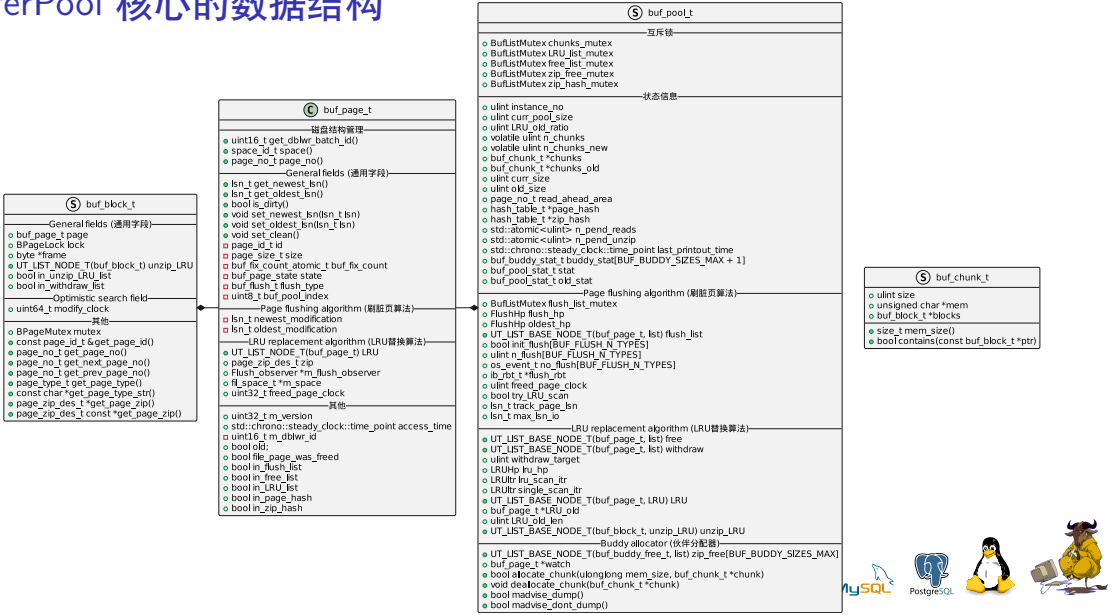

BufferPool 页面管理功能概述

1. page hash（快速访问）
   - 所有的页都由一张哈希表组织，叫 page_hash，可快速的访问到一个页
   - page_hash 的 key 就是 page_id
2. free list（页面申请）
   - 当页面加载到 Buffer Pool 中后，需要为其分配一个 buf_block_t 结构作为描述符
   - free list 记录所有分配空闲的未被占用的 buf_block_t 描述符
3. LRU list（页面淘汰）
   - Buffer Pool 的空间是有限的，由系统变量 `innodb_buffer_pool_size` [2] 控制
   - 当没有空间来存放从磁盘载入的页时，便需要把现有的一些页淘汰掉。使用的就是 LRU 算法
4. flush list（脏页写回）
   - flush list 记录 Buffer Pool 中的所有脏页
   - 同步刷脏，在执行 Query 是调用 `buf_flush_page()` 写盘
   - 异步刷脏，page cleaner 线程定期的将其写回到磁盘

[2] https://dev.mysql.com/doc/refman/8.0/en/innodb-buffer-pool-resize.html

2

BufferPool 启动

初始化 BufferPool

- mysqld 启动时调用 buf_pool_init() 开启多线程创建 BufferPool 实例

```
1437  /** Creates the buffer pool.
1438  @param[in]  total_size     Size of the total pool in bytes.
1439  @param[in]  n_instances    Number of buffer pool instances to create.
1440  @return DB_SUCCESS if success, DB_ERROR if not enough memory or error */
1441  dberr_t buf_pool_init(ulint total_size, ulint n_instances) {
```

- buf_pool_init() 开启多线程快速初始化实例逻辑 (代码有删减)

```
for (i = 0; i < n_instances; /* no op */) {
  std::vector<std::thread> threads;
  for (ulint id = i; id < n; ++id) {
    threads.emplace_back(std::thread(buf_pool_create, &buf_pool_ptr[id], size,
                                     id, &m, std::ref(errs[id])));
  }

  for (ulint id = i; id < n; ++id) {
    threads[id - i].join();
  }

  /* Do the next block of instances */
  i = n;
}
```

创建 BufferPool 实例

- 每个线程调用 `buf_pool_create()` 创建一个 BufferPool 实例，见 ☞ …/buf/buf0buf.cc

```
1193  /** Initialize a buffer pool instance.
1194  @param[in]      buf_pool            buffer pool instance
1195  @param[in]      buf_pool_size size in bytes
1196  @param[in]      instance_no   id of the instance
1197  @param[in,out]  mutex     Mutex to protect common data structures
1198  @param[out] err           DB_SUCCESS if all goes well */
1199  static void buf_pool_create(buf_pool_t *buf_pool, ulint buf_pool_size,
1200                              ulint instance_no, std::mutex *mutex,
1201                              dberr_t &err) {
```

- 调用 `buf_chunk_init()` 为 BufferPool 初始化 Buffer Chunks
- 调用 `buf_block_init()` 初始化 Buffer Block 控制块
- 最终存储在全局变量中，具体查看代码 ☞ storage/innobase/include/buf0buf.h

```
114  /** The buffer pools of the database */
115  extern buf_pool_t *buf_pool_ptr;
```

3

BufferPool 中的页面读写

读取 Page

- buf_page_get() 是其他模块获取数据页的外部接口函数
  - buf_page_get() 是一个宏定义，真正的函数为 buf_page_get_gen
- buffer_page_get_gen() 见代码 ☞ storage/innobase/include/buf0buf.h

```
417  buf_block_t *buf_page_get_gen(const page_id_t &page_id,
418                                const page_size_t &page_size, ulint rw_latch,
419                                buf_block_t *guess, Page_fetch mode,
420                                ut::Location location, mtr_t *mtr,
421                                bool dirty_with_no_latch = false);
```

- 其中 page_id 获取指定的页 / page_size 获取指定的页大小
- 其中 mode 表示读取模式, NORMAL, SCAN, IF_IN_POOL 等
  1. NORMAL：若不在 BufferPool 中则从磁盘文件载入到 BufferPool 中
  2. SCAN：同 NORMAL，但是暗示这是一次大规模的扫描（例如 Table Scan）
  3. IF_IN_POOL：只在 BufferPool 中查找没，如果不在则返回
  4. PEEK_IF_IN_POOL：同 IF_IN_POOL，但不要将数据页放在 LRU list young 区域
  5. IF_IN_POOL_OR_WATCH：同 IF_IN_POOL，但如果不在则设置为 “watch”

读取 Page 流程代码细节分析

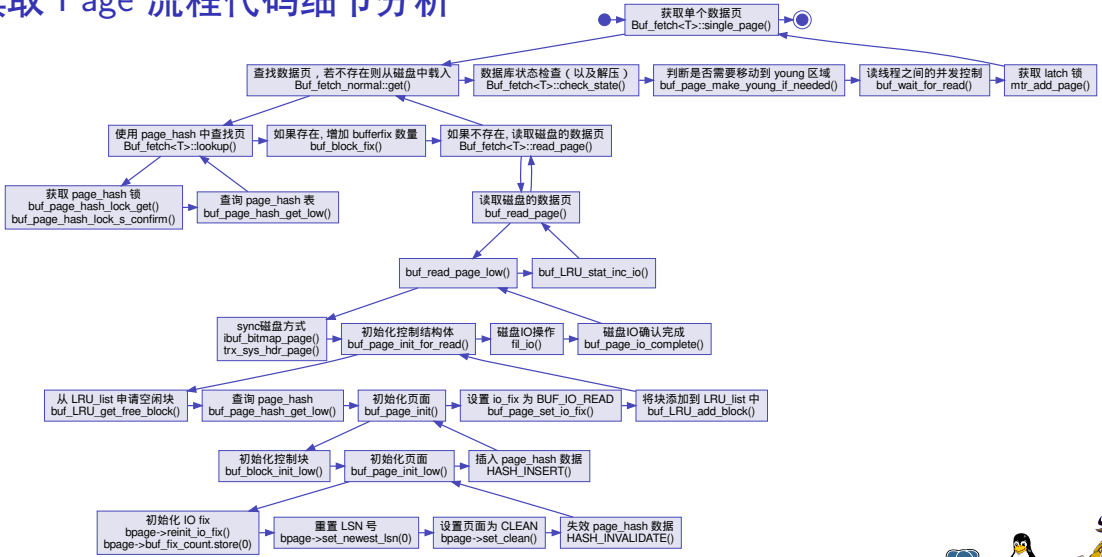

申请 Block

- 从 BufferPool 中申请 1 个 Block 供后续的 Page 读取使用
- 入口函数 `buf_LRU_get_free_block()` 流程如下

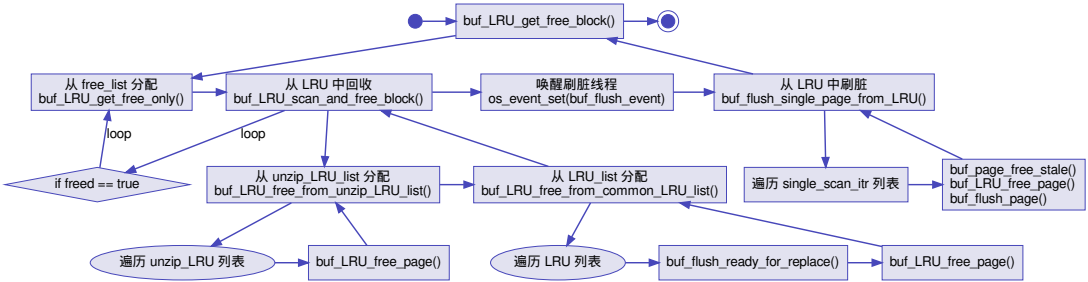

写入 Page

- 同步刷脏的入口函数为 `buf_flush_page()`，同步刷脏过程仅会刷 1 个 Page
- InnoDB 通过严格的 WAL 机制保证数据的一致性，刷脏过程同样如此
  - DoubleWrite 保证 16KB 数据的原子性，不会因为写了 8KB 导致无法恢复
  - 往磁盘上写 16KB 的数据页并不保证是原子的，一般先写 DoubleWrite 后写数据页
    1. 使用同步 IO（fil_io 参数 sync = true）将脏页写到系统表空间中的 DoubleWrite 区域
    2. 使用异步 IO（fil_io 参数 sync = false）将脏页写到用户表空间中
- 需要保证对应的 REDO 日志文件落盘，然后再写入数据页

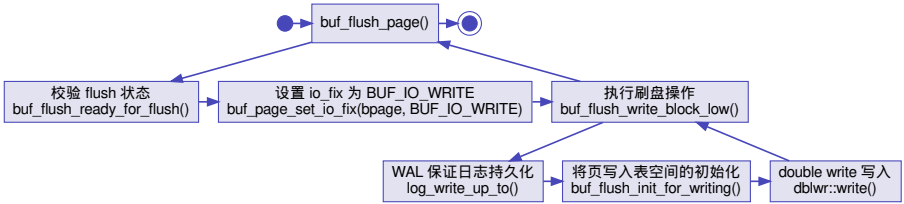

结束